

FALLSTUDIE

NYC Citi Bike Dashboard (2022)

Instacart

Citi Bike

Rockbuster

Influenza

Happiness

Text Mining

TOOLS & BIBLIOTHEKEN

Python · Pandas · NumPy · Plotly · Seaborn · Matplotlib · Streamlit · Kepler.gl

Datenquelle: NYC Citi Bike Systemdaten (2022) — 12 monatliche ZIP-Dateien, ~1,7 Millionen Einzelfahrten

Wetterdaten: NOAA GHCND Tägliche Zusammenfassungen, Station USW00014732 (LaGuardia Airport) — über API abgerufen (TAVG, TMIN, TMAX, PRCP)

Ergebnis: Vollständig deploytes Streamlit-Dashboard mit mehreren Seiten zu saisonalen Trends, Temperaturkorrelation, Stationsnachfrage und geografischen Trip-Clustern

QUELLCODE



github.com/ageelalramadhan/citi-bike-weather-2022 →

5

NOTEBOOKS

1.7M

FAHRTDATEN

365

TAGE
ZUSAMMENGEFÜHRT

6

DASHBOARD -
SEITEN

Projektübersicht

saisonale Schwankungen geplant werden sollen. Dieses Projekt nimmt 1,7 Millionen Einzelfahrten, fügt sie mit NOAA-Tageswetterdaten vom LaGuardia Airport zusammen und macht den kombinierten Datensatz zu einem interaktiven Dashboard für Betriebsentscheidungen.

Geschäftsfrage: Wie sollte Citi Bike die Fahrradversorgung und Rebalancing-Operationen über das Jahr skalieren — und welche Stationen, Jahreszeiten und Umweltfaktoren treiben diese Entscheidung?

Datenpipeline

SCHRITT	QUELLE	AKTION
1. Erfassen	citi_bike_weather_2022	12 monatliche Citi-Bike-ZIP-Dateien + NOAA-API-Wetterdaten via Pagination heruntergeladen
2. Extrahieren	citi_bike_weather_2022	ZIPs mit Pythons zipfile entpackt; alle 12 CSVs via Generator in pd.concat() kombiniert
3. Bereinigen	citi_bike_weather_2022	Zeitstempel geparkt, auf 2022 gefiltert, Null-Datetimes entfernt, NOAA long → wide via pivot()
4. Aggregieren	citi_bike_weather_2022	1,7 Mio. Fahrtenzeilen zu täglichen Fahrtenanzahlen gruppiert; Stationsdaten für Top-10-Ranking aggregiert
5. Mergen	citi_bike_weather_2022	Inner-Join der täglichen Fahrtenanzahl mit NOAA-Wetter nach Datum → citibike_2022_daily_with_weather.csv
6. Visualisieren	exercise_2_3 / exercise_2_4	EDA mit Matplotlib und Seaborn: Zeitreihe, Doppelachsen-Diagramm, Streudiagramm, Verteilungen
7. Geografisch	exercise_2_5	Kepler.gl Trip-Ursprungskarte — räumliche Clusteranalyse der Fahnachfrage 2022
8. Dashboard	exercise_2_6	7-seitige Streamlit-App mit Plotly-Diagrammen, Seitennavigation, Daten-Caching

Saisonalität treibt die Nachfrage

Die durchschnittlichen täglichen Fahrten folgen einem klaren saisonalen Bogen. Die Nutzung steigt von einem Januar-Tief um **33.000 Fahrten/Tag**, erreicht im Spätsommer einen Höhepunkt von rund **115.000 Fahrten/Tag** und fällt mit sinkenden Temperaturen scharf ab. Der Sommerschnitt liegt bei **112.153 Fahrten/Tag** gegen einen Winterschnitt von **57.086** — fast die doppelte Spanne.

Average Daily Rides per Month — 2022




Abbildung 1. Durchschnittliche tägliche Fahrten pro Monat, 2022. Balken nach Saison gefärbt; Referenzlinien markieren die Sommer- (~112K) und Winterdurchschnitte (~57K).

Erkenntnis — Saisonale Skalierungsbasis

Die Winternachfrage (Nov–Apr) liegt im Schnitt bei rund der Hälfte der Sommernachfrage (Jun–Aug). Das quantifiziert direkt, wieviel Rebalancing-Intensität und Personalplanung im Winter reduziert werden können — und wie früh die Sommer-Hochlaufphase beginnen sollte.

Die Überlagerung der täglichen Fahrtenanzahl mit der NOAA-Durchschnittstemperatur zeigt, dass beide Signale tagweise über das ganze Jahr eng zusammenlaufen. Die Streudiagramm-Sicht überführt dieselbe Beziehung in eine einzelne Trendlinie: jede zusätzliche Durchschnittstemperatur in °C entspricht einem messbaren Anstieg der erwarteten Nutzung.




Abbildung 2. Doppelachsen-Tagesreihe: Fahrten (grün) vs. Durchschnittstemperatur (orange gestrichelt). Die Kurven verlaufen über das gesamte Jahr im Gleichtakt.



Abbildung 3. Streudiagramm-Sicht derselben Beziehung, nach Monat eingefärbt. Die Trendlinie ist positiv und annähernd linear im komfortablen Fahrbereich; kalte Wintertage clustern unten links, Sommerhochs oben

Erkenntnis — Temperatur als Planungssignal

Die Tagesnutzung verläuft eng mit der Tagesdurchschnittstemperatur. Der Betrieb sollte die Wettervorhersage (nicht nur den Kalendermonat) als Signal für die Skalierung am Folgetag nutzen — besonders in den Übergangszeiten.

Stationskonzentration: Wo die Nachfrage sitzt

Die Nachfrage ist stark konzentriert. Die meistgenutzte Startstation — W 21 St & 6 Ave — erzeugte 2022 **128.436 Fahrten**. Der Rest der Top 10 liegt in einem engen Band zwischen 94K und 122K, alle in zentralem Manhattan: von Chelsea und Tribeca durch Midtown bis zur Upper East Side.

Top 10 Most Popular Citi Bike Start Stations (2022)




Abbildung 4. Top 10 beliebteste Startstationen. Alle zehn liegen in zentralem Manhattan — hochpriorisierte Kandidaten für Dock-Kapazität und Rebalancing-Frequenz.

Erkenntnis — Rebalancing-Hebel ist konzentriert

Da Fahrtenstarts an wenigen zentralen Manhattan-Stationen geclustert sind, erzielen Rebalancing-Teams überproportionale Effekte, wenn sie sich auf diese Top-10-Stationen

Räumliche Fahrtmuster

Die Kepler.gl-Karte zeigt Bewegungsmuster, die in stationsbezogenen Aggregaten unsichtbar bleiben. Fahrtcluster konzentrieren sich auf Manhattans Geschäftskorridor und das Hudson-Ufer, mit Sekundärclustern in Lower Manhattan und Brooklyn. Die Bögen zeigen, wohin Fahrer tatsächlich fahren — nicht nur, wo sie starten.




Abbildung 5. Kepler.gl-Karte: Fahrtursprünge, -ziele und -bögen über NYC. Die Dichte bestätigt das Manhattan-zentrische Muster aus dem Stationsranking und zeigt sekundäre Knotenpunkte, die das Balkendiagramm allein verbirgt.

Kernergebnisse

Ergebnis 1 — Die Nachfrage verdreifacht sich zwischen Winter und Sommer.

Tagesfahrten skalieren $\sim 3\times$ von Januar ($\sim 33K$) auf August ($\sim 115K$). Der Winterbetrieb sollte etwa halbe Sommerintensität fahren, mit gezieltem Hochlauf ab April.

Ergebnis 2 — Temperatur ist ein stärkeres Planungssignal als der Kalendermonat.

besonders in Übergangszeiten.

Ergebnis 3 — Die Nachfrage ist konzentriert, also ist auch der Rebalancing-Hebel konzentriert.

Die Top-10-Stationen erfassen einen überproportionalen Anteil der Fahrten. Priorisierung dort liefert höheren operativen ROI als gleichmäßige Verteilung.

Ergebnis 4 — Ein deploytes Dashboard macht Ad-hoc-Analysen zu wiederkehrenden Entscheidungen.

Der Schritt von einmaligen Diagrammen zu einer mehrseitigen Streamlit-App gibt Betriebsteams Self-Service-Zugriff auf saisonale, Wetter- und Stationsdaten.

Materialien

↓ Vollständige Fallstudie als PDF

Live-Streamlit-Dashboard ansehen →

</> GitHub-Repository