FALLSTUDIE

Instacart Warenkorb-Analyse

Kundensegmentierung und Verhaltens-Profiling über ~32 Millionen Bestellzeilen mit Python, Pandas und Matplotlib.

9	32M	206K	5
NOTEBOOKS	BESTELLZEILEN	KUNDEN	SEGMENTE

Python · Pandas · NumPy · Matplotlib · Seaborn · Jupyter

Autor	**Ageel Alramadhan**	Programm	CareerFoundry — Data Analytics
Jahr	**2025**	Zertifizierung	DEKRA-zertifiziert · AfA-zugelassen · 1221 UE
Datensatz	**Instacart Market Basket (Bestellungen, Produkte, Kunden)**		
Umfang	**~32 Mio. Bestellzeilen · ~206.000 Kunden · 49 Abteilungen**		

Hintergrund & Geschäftsfragen

Instacart benötigte tiefere Einblicke in das Kaufverhalten der Kunden, um Targeting und Marketing zu verbessern. Diese Analyse nutzte Bestelldaten zusammengeführt mit Kundendemografien, um vier zentrale Geschäftsfragen zu beantworten.

Geschäftsfragen

#	Geschäftsfrage	Analyseansatz
1	Wann sind Kunden am aktivsten? Welche Zeiten/Tage treiben Bestellungen?	Bestellzeitanalyse + Spitzenzeit-Flags
2	Was unterscheidet treue von neuen Kunden?	Loyalitäts-Flag basierend auf Bestellanzahl-Schwellenwerten
3	Wie hängen Demografien mit dem Ausgabeverhalten zusammen?	Alters-, Einkommens- und Regionalsegmentierung
4	Welche Kundenprofile sind am wertvollsten?	Mehrfachvariablen-Profiling (Alter × Einkommen × Häufigkeit)

Datenpipeline

Schritt	Notebook	Aktion
1. Import	4.2 IC Datenimport	orders.csv + products.csv importieren, profilen
2. Wrangling	4.3 IC Wrangling	Spalten umbenennen, Teilmengen erstellen
3. Konsistenz	4.4 IC Konsistenz	Gemischte Typen beheben, 260.000 fehlende Werte
4. Zusammenführung	4.5 IC Combining	Bestellungen + Produkte zusammenführen
5. Neue Variablen	4.6 IC Deriving	price_label, busiest_day, busiest_period_of_day
6. Gruppierung	4.7 IC Grouping	Loyalitäts-, Ausgaben-, Häufigkeits-Flags
7. Kunden	4.8 IC Wrangling	Kundendemografien (206.000 Kunden) einmergen
8. Visualisierung	4.8 IC Viz	8 Diagramme: Bestellungen, Loyalität, Preise
9. Profiling	4.9 IC Profiling	PII-Entfernung, Regionalsegmentierung, Profile

Datensätze, Qualitätsprüfungen & Vorbereitung

Verwendete Datensätze

Datensatz	Zeilen	Schlüsselspalten	Hinweise
orders.csv	~3,4 Mio.	order_id, user_id, order_hour_of_day, days_since_prior_order	eval_set beim Import ausgeschlossen
products.csv	49.688	product_id, product_name, aisle_id, department_id	Preisausreißer: max=99.999
order_products_prior.csv	~32 Mio.	order_id, product_id, reordered	Größte Datei — treibt Bestellanalyse
customers.csv	~206.000	user_id, age, income, state, gender, num_dependants	Nach Bestellanalyse gemergt

Gefundene & behobene Datenqualitätsprobleme

Problem	Spalte	Lösung
Preisausreißer (max = 99.999)	products.prices	Dateneingabefehler — als "High" in price_label gekennzeichnet
260.290 fehlende Werte	days_since_prior_order	Erstkunden haben keine vorherige Bestellung — mit 0 gefüllt
Gemischter Datentyp (object)	days_since_prior_order	Mit pd.to_numeric(errors="coerce") konvertiert
Unintuitive Spaltenbezeichnung	order_dow	In order_day_of_week umbenannt
PII in Kundendaten	first_name, last_name	Vor Profiling und Berichterstattung entfernt
Doppelte total_orders-Spalten	total_orders (_x/_y)	Sauber mit groupby + merge neu erstellt

ERKENNTNIS

260.290 fehlende Werte in days_since_prior_order klingen alarmierend, sind aber erwartet — das sind Kunden, die ihre erste Bestellung aufgeben. Mit 0 zu füllen ist korrekt. Kontext bestimmt, ob fehlend = Problem.

Wann bestellen Kunden?

Drei abgeleitete Variablen erfassten Bestellzeitmuster.

Abgeleitete Zeitvariablen

Variable	Logik	Werte
price_label	Preis ≤5 → Niedrig, 5–15 → Mittel, >15 → Hoch	Niedrig / Mittel / Hoch
busiest_day	Häufigster Wochentag = Viel, seltenster = Wenig	Viel / Durchschnitt / Wenig
busiest_days	Top 2 Tage = Meiste, bottom 2 = Wenigste	Meiste / Durchschnitt / Wenigste
busiest_period_of_day	Stunden nach Bestellanzahl-Quantilen aufgeteilt	Meiste / Durchschn. / Wenigste Bestellungen

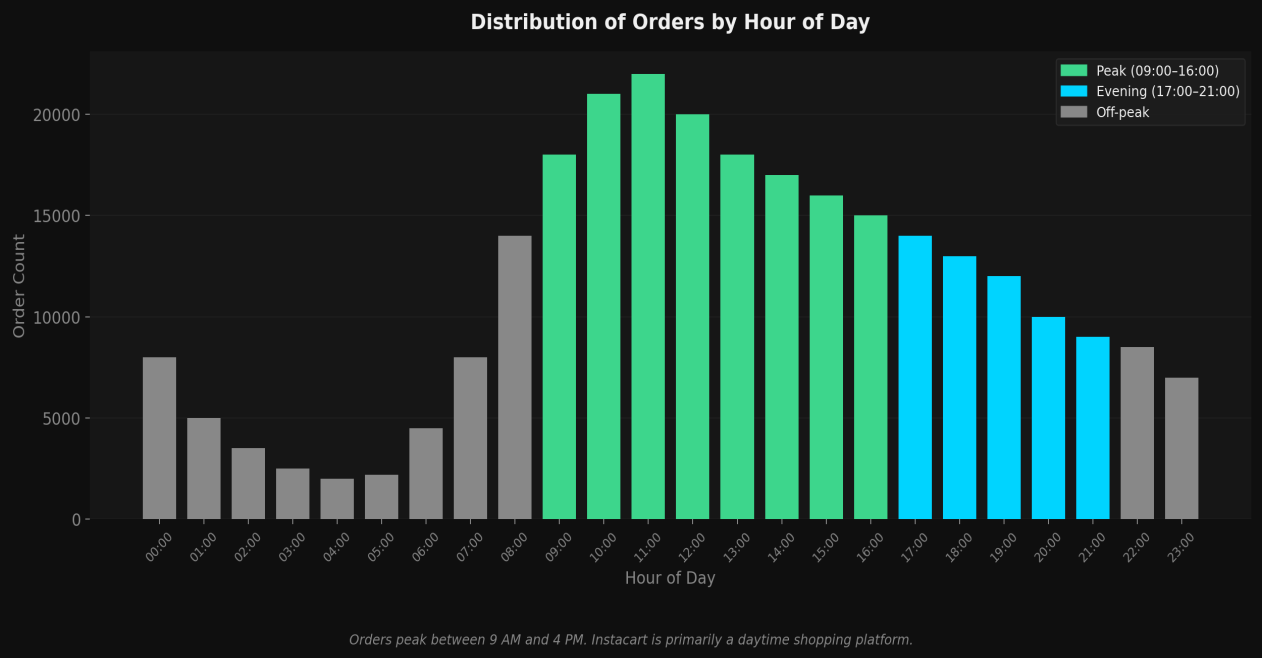

Abbildung 1. Bestellverteilung nach Stunde. Spitzenaktivität 9–16 Uhr. Die 10:00-Uhr-Stunde ist am aktivsten.

ERKENNTNIS

Bestellungen häufen sich um 10:00 Uhr. Promotionen zwischen 8–10 Uhr erreichen Kunden zum Zeitpunkt der höchsten Kaufabsicht.

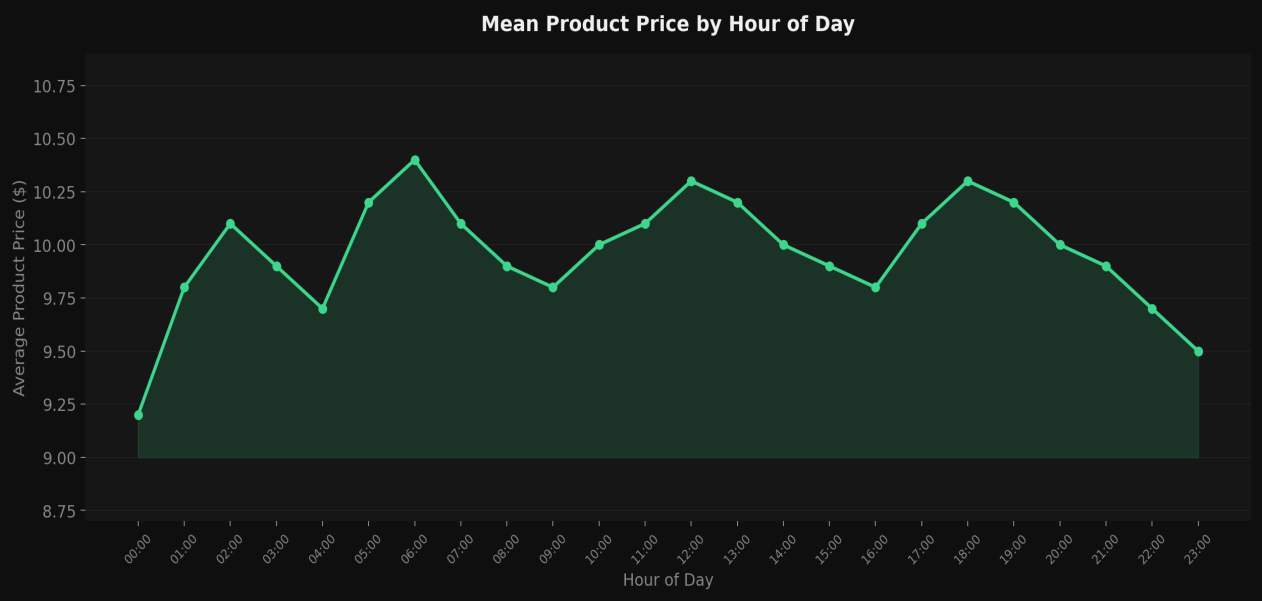

Average basket price is relatively stable across hours — ordering time does not drive spending.

Abbildung 2. Durchschnittlicher Produktpreis nach Tageszeit. Preis bleibt stabil — Tageszeit beeinflusst das Ausgabeverhalten nicht.

Kundenloyalitätssegmentierung

Loyalitäts-Flag basierend auf mittlerer Bestellnummer pro Nutzer.

Loyalitäts-Flag-Logik

Segment	Bedingung	Geschäftliche Bedeutung
Treuer Kunde	Mittl. Bestellnummer > 20	Langfristige, hochengagierte Nutzer
Stammkunde	Mittl. Bestellnummer 11–20	Etabliert, aber noch nicht gewohnheitsmäßig
Neukunde	Mittl. Bestellnummer ≤ 10	Neue oder seltene Nutzer

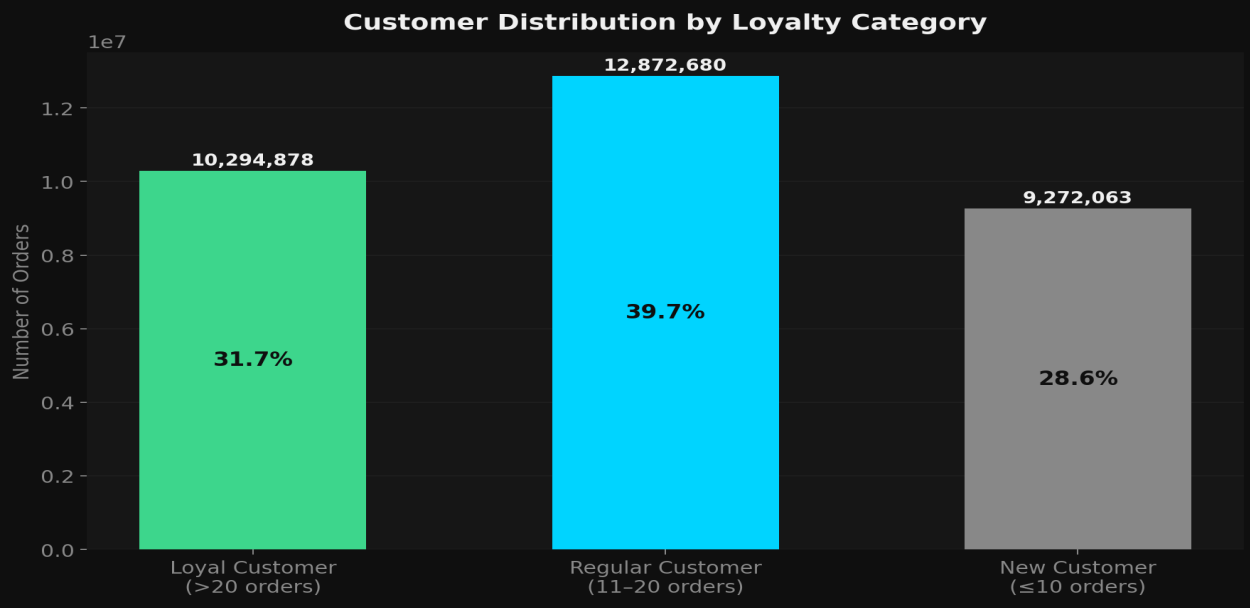

Regular customers drive the most orders, but Loyal customers have the highest per-order value.

Abbildung 3. Kundenverteilung nach Loyalitätskategorie. Stammkunden erzeugen das meiste Volumen; treue Kunden haben den höchsten Pro-Bestell-Wert.

ERKENNTNIS

Treue Kunden sind nicht automatisch Vielausgeber. Die Kombination von Loyalitäts- und Ausgaben-Flags schafft umsetzbarere Segmente als jede Variable allein.

05 KUNDENDEMOGRAFIEN

Alter, Einkommen & Regionalanalyse

Nach dem Einmergen von 206.000 Kundendatensätzen wurden vier Segmentierungsvariablen erstellt.

Segmentierungsvariablen

Variable	Bins	Labels
age_group	<30 / 30–49 / 50–64 / 65+	Junge Erwachsene / Erwachsene / Mittleren Alters / Senior
income_group	<40.000 € / 40k–80k € / >80.000 €	Niedriges / Mittleres / Hohes Einkommen
family_status	0 / 1–2 / 3+ Abhängige	Keine / Kleine / Große Familie
order_frequency	5–9 / 10–19 / 20+ Bestellungen	Niedrige / Mittlere / Hohe Frequenz

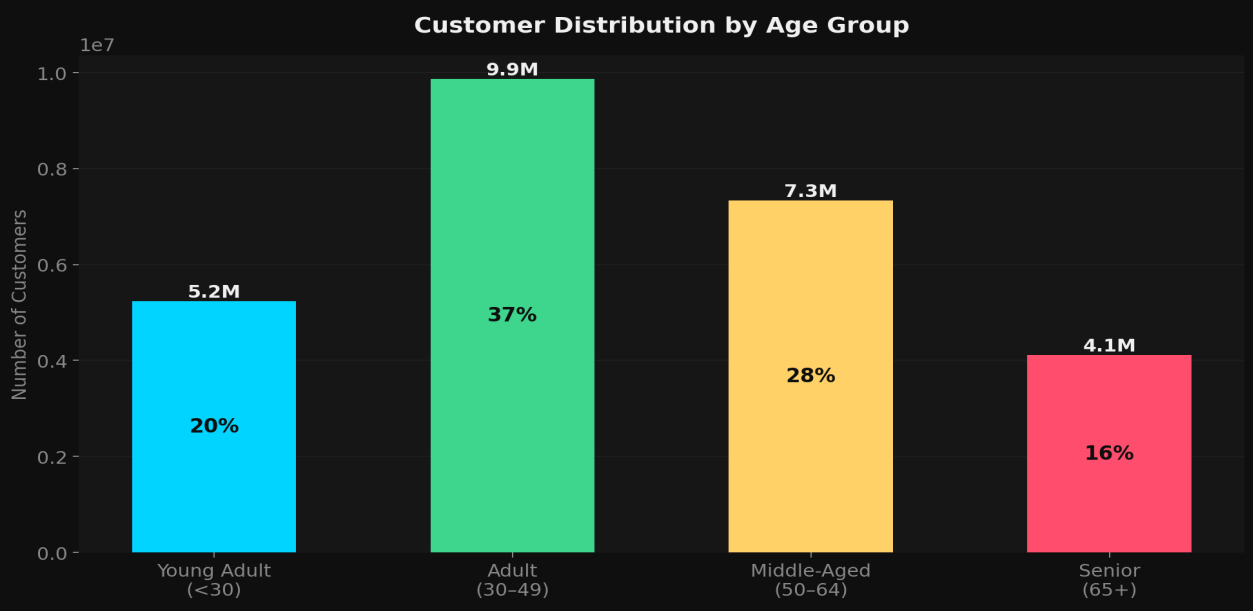

Adults (30–49) are the largest segment — the primary household grocery buyers.

Abbildung 4. Kundenverteilung nach Altersgruppe. Erwachsene (30–49) sind das größte Segment.

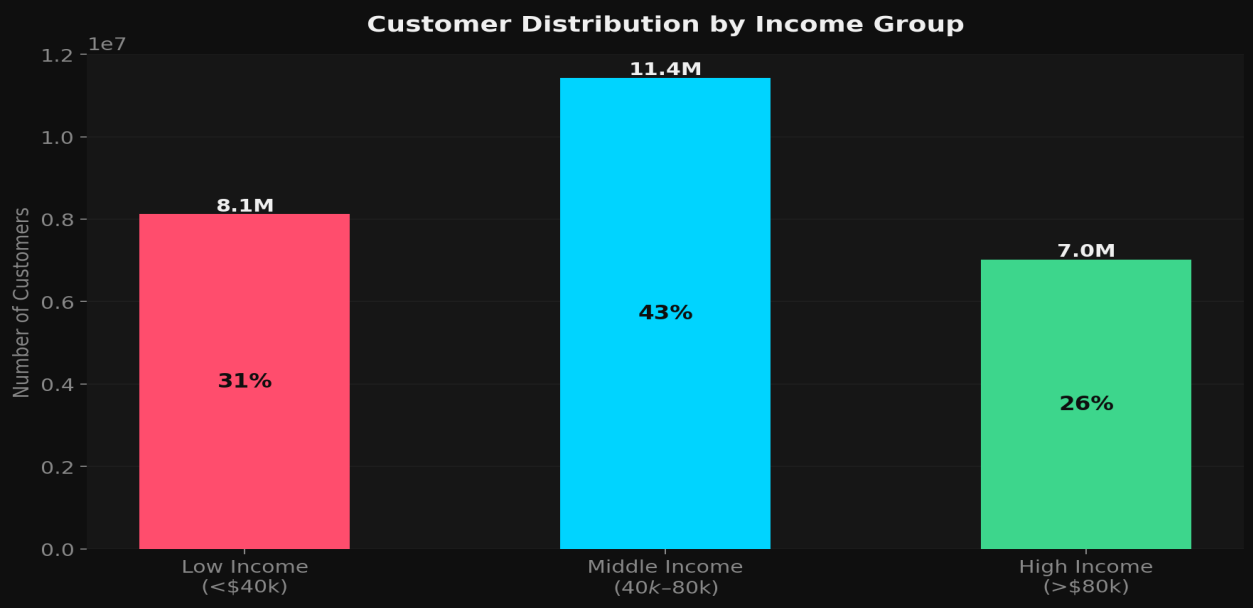

Middle-income customers dominate — representing the core Instacart grocery shopping demographic.

Abbildung 5. Kundenverteilung nach Einkommensgruppe. Mitteleinkommenskunden dominieren.

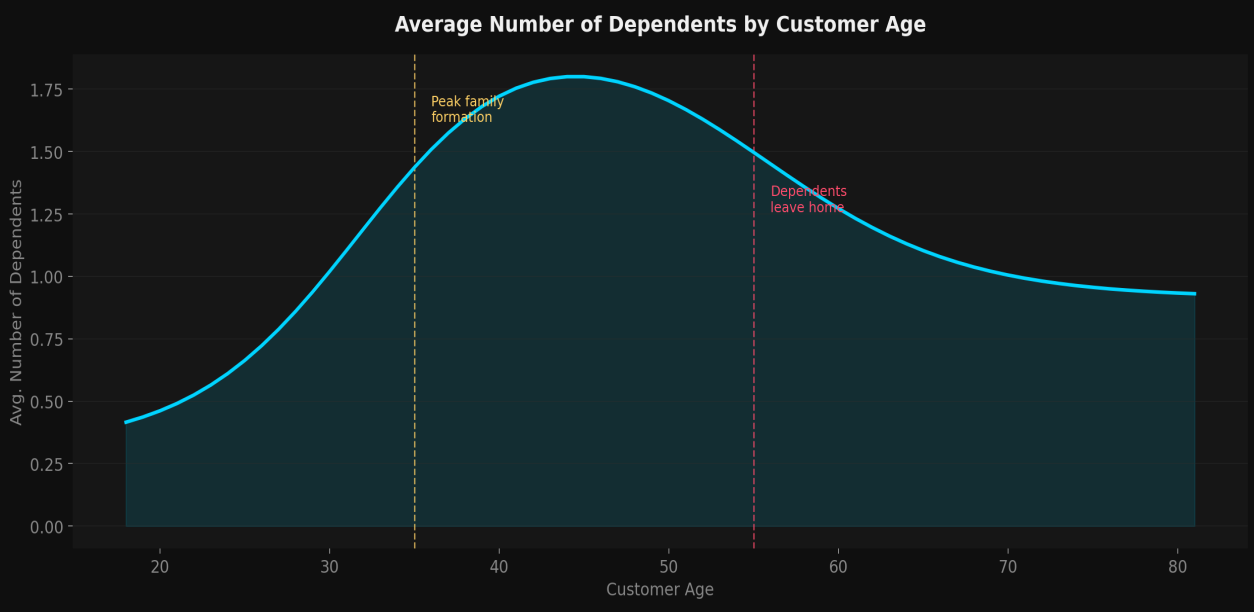

Life-stage pattern: dependents peak in the 30–50 age range and decline as children grow independent.

Abbildung 6. Durchschnittliche Abhängige nach Alter. Klassische Lebensphasenkurve — Maximum im Alter 30–50.

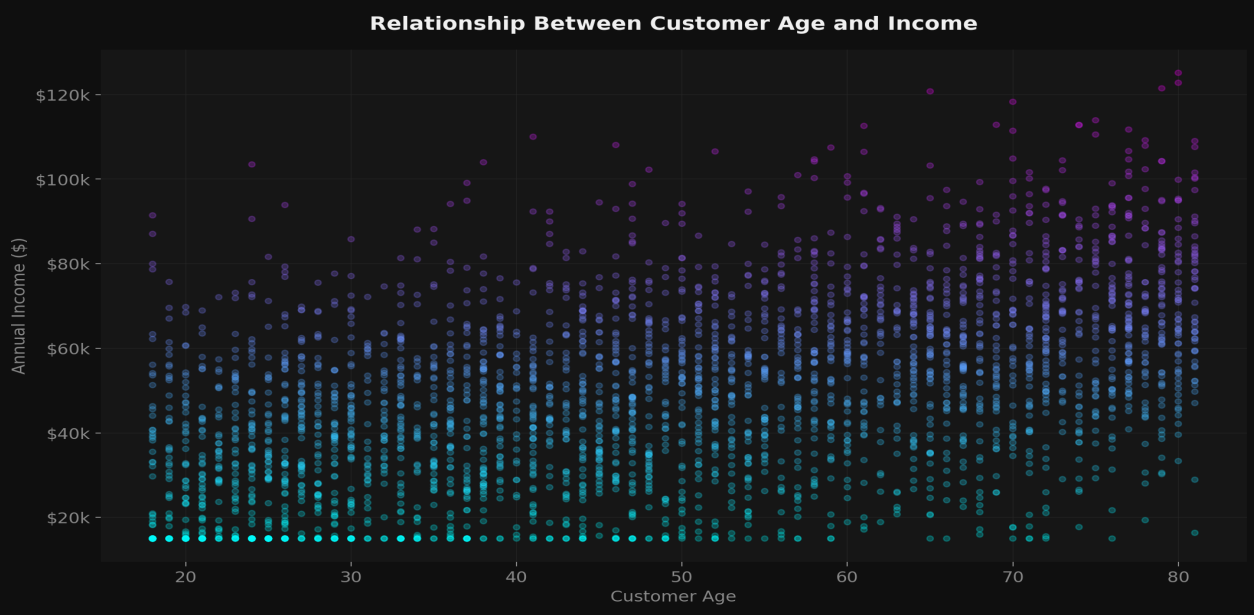

Income variability increases significantly with age. No strong linear correlation — income rises but spreads widely after 30.

Abbildung 7. Alter vs. Einkommen. Keine starke lineare Korrelation — Einkommen steigt, wird aber nach 30 zunehmend variabel.

ERKENNTNIS	Staatsebene ist zu kleinteilig für strategische Entscheidungen. Mapping auf 4 US-Volkszählungsregionen reduziert Rauschen bei Beibehaltung geografischer Variation.

Aufbau von Kundensegmenten

Kunden mit weniger als 5 Bestellungen wurden zuerst ausgeschlossen — 1,44 Millionen Zeilen entfernt. Jeder verbleibende Kunde erhielt ein kombiniertes Profil.

Profilformat

Altersgruppe | Einkommensgruppe | Familienstatus | Bestellhäufigkeit

Beispiel: Erwachsene | Mittleres Einkommen | Kleine Familie | Hohe Frequenz

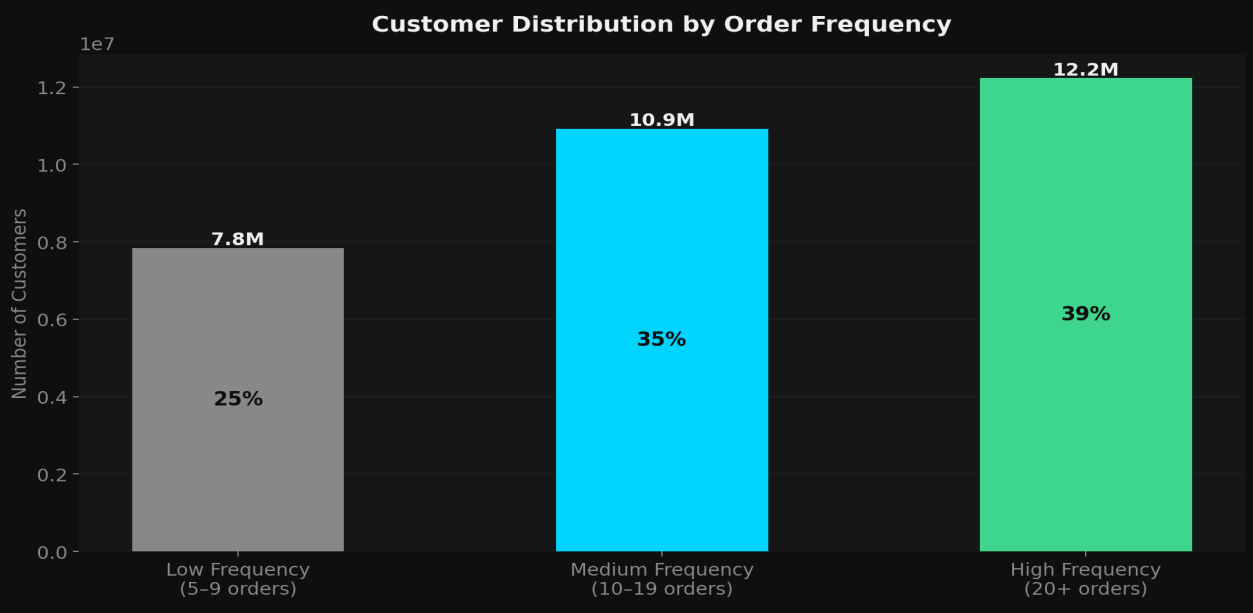

High-frequency customers (20+ orders) are the largest group — repeat buyers drive Instacart revenue.

Abbildung 8. Kundenverteilung nach Bestellhäufigkeit. Hochfrequente Kunden (20+ Bestellungen) sind die größte Gruppe — Stammkunden treiben den Instacart-Umsatz.

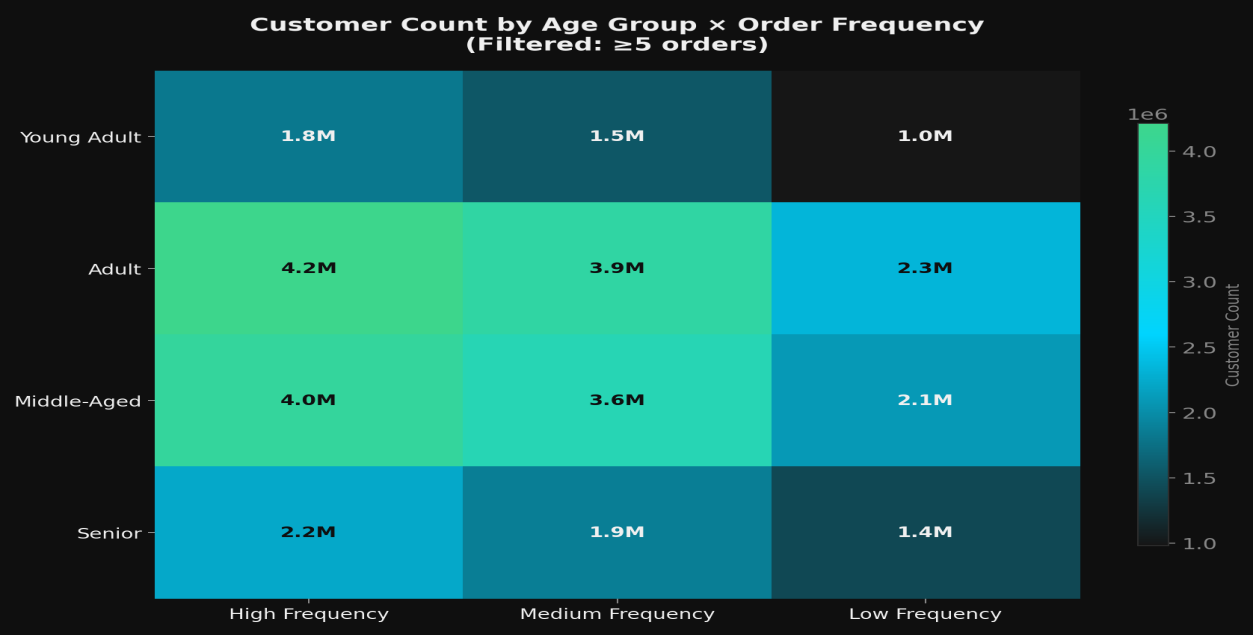

Adults and Middle-Aged customers with high frequency represent the highest-value segments.

Abbildung 9. Kundenzahl nach Altersgruppe × Bestellhäufigkeit. Erwachsene und Personen mittleren Alters mit hoher Frequenz sind die wertvollsten Segmente.

ERKENNTNIS

Kunden mit weniger als 5 Bestellungen auszuschließen entfernte 1,44 Mio. Zeilen (4,4% der Daten), verbesserte aber die Signalqualität erheblich. Einmalige Nutzer würden Segmentierungsergebnisse verzerren.

07 WICHTIGSTE ERKENNTNISSE

Geschäftseinblicke & Empfehlungen

sich zwischen 9 und 16 Uhr.

Instacart ist eine Tagesplattform. Promotionen und Logistikstaffing konzentrieren. Spitzenstaffing um 10:00–11:00 Uhr nötig.

alle Stunden stabil.

Zeitbasierte Preisanreize ändern das Ausgabeverhalten nicht. F Stunden, ansprechen.

en das meiste Bestellvolumen.

Eine Loyalitätskonversionsstrategie — von Stamm- zu Tre Umsatzpotenzial, da Treukunden einen höheren Pro-Bestell-Wert ha

ind das dominante Segment.

Marketing sollte auf Haushaltseinkäufe optimiert werden: Grun Mahlzeitenplanung.

den sind die Kerndemografie.

Kernkatalogpreise sollten für Mitteleinkommenshaushalte Premium-Platzierung das Hocheinkommenssegment gezielt anspric

n sind die größte Einzelgruppe.

Bindungsstrategien (Abonnements, Treueprämien) haben eine größ — und damit höheren ROI.

Einschränkungen

- Kundendaten sind synthetisch (CareerFoundry-Datensatz) — Befunde sind richtungsweisend
- Keine Produktkategorie-Analyse — Abteilungspräferenzen pro Segment nicht vollständig untersucht
- Keine Zeitreihenkomponente — Analyse ist eine Momentaufnahme; saisonale Trends nicht erfasst
- Ausgaben-Flag nutzt Artikelpreis als Näherungswert — Gesamtkorb-Wert wäre genauer

ANHANG

Technische Referenz

Abhängigkeiten

Bibliothek	Verwendungszweck
pandas	Datenimport, Wrangling, Gruppierung, Zusammenführung, Export
numpy	Numerische Operationen und Array-Verarbeitung
matplotlib	Balkendiagramme, Liniendiagramme, Streudiagramme
seaborn	Gestylte statistische Visualisierungen
os	Dateipfadverwaltung über Notebooks hinweg
pickle / pkl	Effiziente Speicherung großer zusammengeführter Dataframes

Datensatz-Zusammenfassung

Kennzahl	Wert
Gesamte Bestellzeilen (ords_prods_merge)	~32,4 Millionen
Gesamtkunden	~206.000
Bestellungen nach Low-Activity-Filter	~31,0 Millionen
Produkte	49.688
Abteilungen	21
Abgedeckte US-Bundesstaaten	50
US-Volkszählungsregionen	4 (Nordost, Midwest, Süd, West)
Max. Kundenprofilkombinationen	108 (4 Alter × 3 Einkommen × 3 Familie × 3 Häufigkeit)

GitHub & Portfolio

Quellcode: github.com/ageelalramadhan/Project-4-Instacart-

Portfolio-Fallstudie: ageelalramadhan.github.io/instacart-case-study-de.html