

FALLSTUDIE

INSTACART WARENKORB-ANALYSE

TOOLS & BIBLIOTHEKEN

Python · Pandas · NumPy · Matplotlib · Seaborn · Jupyter

Datensatz: Instacart Market Basket — Bestellungen, Produkte, Kunden (~32 Mio. Bestellzeilen, ~206.000 Kunden, 49.693 Produkte in 21 Abteilungen)

Ergebnis: Kundensegmentierung über 5 Dimensionen: Loyalität, Ausgaben, Alter, Einkommen und Bestellhäufigkeit



QUELLCODE

github.com/ageelalramadhan/Project-4-Instacart- →

9

NOTEBOOKS

32M

BESTELLZEILEN

206K

KUNDEN

5

SEGMENTE

PROJEKTÜBERSICHT

Instacart benötigte tiefere Einblicke in das Kaufverhalten der Kunden, um Targeting und Marketing zu verbessern. Diese Analyse nutzte Bestelldaten, zusammengeführt mit Kundendemografien, um vier zentrale Geschäftsfragen zu beantworten.

GESCHÄFTSFRAGEN

#	GESCHÄFTSFRAGE	ANALYSEANSATZ
1	Wann sind Kunden am aktivsten? Welche Zeiten/Tage treiben Bestellungen?	Bestellzeit-Analyse
2	Was unterscheidet treue Kunden von neuen?	Loyalitäts-Flag (f)
3	Wie hängen Demografie und Ausgabeverhalten zusammen?	Alter-, Einkommens-
4	Welche Kundenprofile sind am wertvollsten?	Multivariates Pro

DATENPIPELINE

SCHRITT	NOTEBOOK	AKTION
1. Import	4.2	orders.csv + products.csv importieren, profilieren und vorschauen
2. Wrangling	4.3	Spalten umbenennen, Teilmengen erstellen, bereinigte Daten ex
3. Konsistenz	4.4	Gemischte Typen korrigieren, 206.209 fehlende Werte behande
4. Merging	4.5	orders + order_products + products zu einem DataFrame verbir
5. Abgeleitete Vars	4.6	price_label, busiest_day, busiest_period_of_day erstellen
6. Gruppierung	4.7	Loyalitäts-Flag, Ausgaben-Flag, Bestellhäufigkeits-Flag
7. Kunden	4.8	Kundendemografien zusammenführen (206K Kunden)
8. Visualisierung	4.8	8 Diagramme: Bestellungen, Loyalität, Preise, Demografie
9. Profiling	4.9	PII-Entfernung, Regionalsegmentierung, Kundenprofile

DATENQUALITÄT

Erkenntnis — Fehlende Werte

206.209 fehlende Werte in days_since_prior_order sind **erwartet**, nicht fehlerhaft. Die Zahl entspricht exakt der Kundenanzahl (206.209), also ist jeder fehlende Wert die erste Bestellung eines Kunden. Das Auffüllen mit 0 erhält die Bedeutung.

BESTELLZEIT-ANALYSE




Abbildung 1. Bestellungen erreichen ihren Höhepunkt zwischen 9 und 16 Uhr. Die Personalplanung sollte sich an dieser Verteilung orientieren.




Abbildung 2. Das Fenster 10–11 Uhr ist die absolute Spitze. Aktionen und Logistik sollten sich auf 9–16 Uhr konzentrieren.

PREISVERHALTEN




Abbildung 3. Der Durchschnittspreis ist über alle 24 Stunden praktisch konstant. Zeitabhängige Preisanreize würden das Verhalten nicht ändern.

LOYALTÄTSEGMENTIERUNG





Abbildung 4. Drei-Stufen-Loyalität nach mittlerer Bestellnummer je Kunde (Neu ≤ 10 , Regulär 10–20, Loyal > 20). Neukunden stellen die meisten Bestellzeilen (12,1 Mio., 37 %), Loyal 10,9 Mio. (34 %), Regulär 9,4 Mio. (29 %). Der Median-Artikelpreis liegt in allen drei Gruppen bei 7,4.

DEMOGRAFIE


Customers by Age Group (n = 162,633)



Adults (30-49) are the largest group, seniors the second largest. Source: notebook 4.9.

Abbildung 5. Erwachsene (30-49) sind die größte Gruppe (50.981 Kunden, 31 %), Senioren (65+) die zweitgrößte (43.250, 27 %). Gezählt werden Kunden mit 5+ Bestellungen.


Customers by Income Group (n = 162,633)



High-income households are the largest group (61%). Bins as defined in notebook 4.9.

Abbildung 6. Haushalte mit hohem Einkommen (> 80.000 \$) sind mit Abstand die größte Gruppe: 98.524 Kunden (61 %), gegenüber 51.484 mit mittlerem und 12.625 mit niedrigem Einkommen.

Relationship Between Customer Age and Income



Income variability increases significantly with age. No strong linear correlation — income rises but spreads widely after 30.

Abbildung 7. Alter vs. Einkommen. Keine starke lineare Korrelation — Einkommen steigt, wird aber nach 30 zunehmend variabel.

Erkenntnis — Regionalsegmentierung

Eine Analyse auf Bundesstaatenebene ist zu granular — 50 Gruppen mit zu wenig Daten je Gruppe. Die Abbildung auf 4 US-Census-Regionen reduziert Rauschen und erhält die geografische Variation.

KUNDENPROFILING

Niedrigaktivitäts-Kunden (weniger als 5 Bestellungen) wurden ausgeschlossen — 1,44 Millionen Zeilen entfernt. Jeder verbleibende Kunde erhielt ein kombiniertes Profil:

```
df_filtered['customer_profile'] = (  
    df_filtered['age_group'].astype(str) + " | " +  
    df_filtered['income_group'].astype(str) + " | " +  
    df_filtered['family_status'].astype(str) + " | " +  
    df_filtered['order_frequency'].astype(str)  
)  
# Beispiel: "Adult | Middle income | Small family | High frequency"
```

Customers by Order Frequency (customers with 5+ orders, n = 162,633)




Abbildung 8. Nach Kundenanzahl sind die drei Häufigkeitsstufen ähnlich groß (60.937 / 50.965 / 50.731). Nach Volumen nicht: Hochfrequenz-Kunden sind 31 % der Kunden, aber 64 % aller Bestellzeilen (19,9 von 31,0 Mio.).

Top 5 Customer Profiles by Order Lines (customers with 5+ orders)




Abbildung 9. Die fünf häufigsten kombinierten Profile. Alle fünf sind Hochfrequenz-Haushalte mit kleiner Familie; Einkommen und Lebensphase variieren. Verhalten, nicht Demografie, definiert die Spitze der Kundenbasis.

Der Ausschluss von Kunden mit weniger als 5 Bestellungen entfernte 1,44 Mio. Zeilen (4,4% der Daten), verbesserte aber die Signalqualität deutlich.

KERNERGEBNISSE

Ergebnis 1 — Bestellungen erreichen ihren Höhepunkt zwischen 9 und 16 Uhr.

Instacart ist eine Tagesplattform. Aktionen und Logistik sollten sich auf das Fenster 9–16 Uhr konzentrieren. Spitzenpersonal um 10–11 Uhr.

Ergebnis 2 — Der Produktpreis ist über alle Stunden stabil.

Zeitabhängige Preisanreize ändern das Ausgabeverhalten kaum. Aktionen sollten Segmente, nicht Stunden, ansprechen.

Ergebnis 3 — Neukunden stellen weiterhin die meisten Bestellzeilen (37 %).

Der Artikelpreis ist über alle Loyalitätsstufen gleich (Median 7,4). Der Hebel ist also die Bestellhäufigkeit (Neu zu Regulär, Regulär zu Loyal), nicht der Warenkorbwert.

Ergebnis 4 — Erwachsene (30–49) sind die größte Altersgruppe, Senioren die zweitgrößte.

Senioren sind 27 % der aktiven Kunden und führen das häufigste Hochfrequenz-Profil an. Kampagnen, die von einer jungen Familienzielgruppe ausgehen, würden über ein Viertel der aktiven Kunden verfehlen.

Ergebnis 5 — Haushalte mit hohem Einkommen sind die Kernzielgruppe (61 %).

Das Einkommen ist für den Großteil der Basis nicht die Grenze. Premium-Platzierungen haben eine große Zielgruppe, preisgetriebene Aktionen eine kleine (8 % niedriges Einkommen).

Ergebnis 6 — Hochfrequenz-Kunden erzeugen 64 % der Bestellzeilen.

Ein Drittel der Kunden erzeugt zwei Drittel des Volumens. Die mittlere Stufe (10–19 Bestellungen, 50.965 Kunden) eine Stufe nach oben zu bewegen, ist der Retention-Test mit dem größten Hebel.

MATERIALIEN

```
</> GitHub-Repository
```