

20. JAHRHUNDERT TEXT MINING & NLP

TOOLS & BIBLIOTHEKEN

Python · Selenium · NLTK · TextBlob · spaCy · NetworkX · cdlib (Leiden)

Datenquelle: Wikipedia — „Key Events of the 20th Century“ (via Selenium gescrapt, ~17.000 Wörter nach Bereinigung)

Ergebnis: Co-Vorkommen-Netzwerk von 21 Ländern über 53 einzigartige geopolitische Kanten mit Community Detection und Zentralitätsanalyse



QUELLCODE

github.com/ageelalramadhan/20th-century →

4

NOTEBOOKS

21

LÄNDER
ZUGEORDNET

53

NETZWERKKANTEN

4

LEIDEN-
COMMUNITIES

PROJEKTÜBERSICHT

Dieses Projekt wendet eine vollständige NLP-Pipeline auf einen Wikipedia-Artikel über **Key Events of the 20th Century** an. Das Ziel: von rohen Webdaten zu einer strukturierten, visuellen Darstellung, welche Länder historisch am stärksten verbunden waren — und wie ihre Co-Vorkommen-Muster auf reale geopolitische Allianzen und Konflikte abbilden.

Geschäftsfrage: Welche Länder wurden in den Ereignissen des 20. Jahrhunderts am häufigsten gemeinsam erwähnt, und spiegelt ihre Beziehungsstruktur die tatsächlichen Allianzen und Konflikte der Epoche wider?

PIPELINE-ARCHITEKTUR

SCHRITT	TOOL	ERGEBNIS
1. Web-Scraping	Selenium + ChromeDriver	20th_century_key_events.txt
2. Text-Bereinigung	Custom Python	Navigations-Elemente entfernt, sauberer K
3. Text Mining	NLTK + TextBlob	Worthäufigkeit, POS-Tags, Länderkennung
4. NER-Extraktion	spaCy (en_core_web_sm)	GPE-Entitätspaare pro Satz
5. Alias-Normalisierung	Custom Alias-Dict	UK/Britain/U.K. → United Kingdom
6. Netzwerkaufbau	NetworkX	Ungerichteter Graph: 21 Knoten, 53 Kanten
7. Community-Erkennung	Leiden (cdlib)	4 geopolitische Cluster identifiziert
8. Zentralitätsanalyse	NetworkX	Grad-, Closeness-, Betweenness-Werte
9. Visualisierung	Pyvis + Matplotlib	Interaktives HTML + Publikationscharts

PHASE 1 – WEB-SCRAPING

Selenium mit ChromeDriver (Headless-Modus) hat den vollständigen Body-Text des Wikipedia-Artikels programmatisch gescrapt. Die Rohausgabe enthielt Navigationselemente — Menüs, Edit-Links, Tool-Labels — die NER-Ergebnisse durch irrelevante Entitäten verfälscht hätten.

```
options = Options()
options.add_argument("--headless")
driver = webdriver.Chrome(executable_path=str(driver_path), options=options)
driver.get("https://en.wikipedia.org/wiki/Key_events_of_the_20th_century")
page_text = driver.find_element(By.TAG_NAME, "body").text
driver.quit()

# Zeilenweise Bereinigung – Navigations-Artefakte entfernen
bad_starts = ("Jump to content", "Main menu", "Search", "Tools", "Edit", "View histor
clean_lines = [l.strip() for l in page_text.splitlines()
                if l.strip() and not l.strip().startswith(bad_starts)]
clean_text = "\n".join(clean_lines)
```

Erkenntnis — Bereinigung schlägt Modellwahl

Roh gescrapter Text enthielt Wikipedia-Chrome (Menüs, Edit-Links, Tool-Labels), die NER fälschlich als Orte klassifizieren würde. Das Filtern dieser Muster vor NER brachte den größten einzelnen Genauigkeitsgewinn der Pipeline.

PHASE 2 — TEXT MINING




Abbildung 1. Häufigste bedeutungstragende Tokens nach Stoppwort-Filterung. Geopolitisches und konfliktbezogenes Vokabular dominiert.




Abbildung 2. Häufigkeiten der Länderkennungen. Hauptmächte der Alliierten und Achsenmächte dominieren die Verteilung.

PHASE 3 — NAMED ENTITY RECOGNITION

Das spaCy-Modell `en_core_web_sm` extrahierte geopolitische Entitäten (GPE-Label). Für jeden Satz wurden alle eindeutigen GPE-Paare als Co-Vorkommen-Kanten erfasst. Ein Alias-Wörterbuch normalisierte Varianten (z. B. UK / Britain / U.K. → United Kingdom) vor dem Aufbau der Kanten.

Erkenntnis — Alias-Normalisierung verhindert Knoten-Duplikation

Ohne Alias-Mapping werden „UK“, „Britain“ und „United Kingdom“ zu drei verschiedenen Knoten — die echte Konnektivität des Landes wird zerlegt. Ein Custom-Alias-Dict konsolidiert sie zu einem kanonischen Knoten.

PHASE 4 — NETZWERKAUFBAU & COMMUNITY-ERKENNUNG

Aus den GPE-Paaren wurde ein ungerichteter NetworkX-Graph aufgebaut: **21 Knoten, 53 Kanten**, Dichte 0,252, Clustering-Koeffizient 0,552. Der Leiden-Algorithmus (via `cdlib`) erkannte vier Communities, die reale Allianz-Strukturen des 20. Jahrhunderts widerspiegeln.

Country co-occurrence network ☐ 20th century key events
21 countries · 53 connections extracted via NER from Wikipedia




Abbildung 3. Geopolitisches Co-Vorkommen-Netzwerk. Knotengröße spiegelt Grad-Zentralität; Farbe spiegelt Leiden-Community wider. Deutschland sitzt im strukturellen Zentrum.




Abbildung 4. Community-Erkennungsergebnis: Eurasien/Kalter Krieg, Mittel-/Nordeuropa, West-/Mitteleuropa und Angloamerikanisch/Italien.

COMMUNITY-DETECTION-ERGEBNISSE

COMMUNITY	MITGLIEDER	HISTORISCHER KONTEXT
Eurasien / Kalter Krieg	China, Indien, Japan, Russland, Sowjetunion, UK, Finnland	Dynastie / Kalter Krieg
Mittel- / Nordeuropa	Österreich, Deutschland, Dänemark, Norwegen, Schweden	Mittelalter / Nordeuropa
West- / Mitteleuropa	Belgien, Frankreich, Niederlande, Polen, Ungarn	Westliche Mitteleuropa
Angloamerikanisch + Italien	Australien, Kanada, USA, Italien	Angloamerikanisch + Italien

PHASE 5 — ZENTRALITÄTSANALYSE




Abbildung 5. Grad-, Closeness- und Betweenness-Zentralität für alle 21 Knoten. Deutschland dominiert alle drei Metriken.




Abbildung 6. Heatmap-Ansicht der Zentralitätsmetriken. Deutschland, Frankreich, Russland und das Vereinigte Königreich besetzen die Spitze.

INTERAKTIVES NETZWERK




Abbildung 7. Statischer Screenshot des interaktiven Pyvis-Netzwerks. Die volle HTML-Datei erlaubt Zoom, Pan und Knoten-Inspektion.

Erkenntnis — Quantitative Methode, qualitative Validierung

Die vom Leiden-Algorithmus erkannten Communities — ohne historische Priors — passen zu bekannten Allianz-Strukturen des 20. Jahrhunderts. Das ist starke Validierung dafür, dass NLP-abgeleitete Netzwerke reale geopolitische Strukturen aus unstrukturiertem Text rekonstruieren können.

KERNERGEBNISSE

Ergebnis 1 — Deutschland sitzt im strukturellen Zentrum.

Deutschland erzielt die höchsten Werte bei Grad-, Closeness- und Betweenness-Zentralität — konsistent mit seiner zentralen Rolle in beiden Weltkriegen und im Kalten Krieg.

Ergebnis 2 — Erkannte Communities entsprechen realen Allianz-Strukturen.

Die vier Leiden-Communities bilden anerkannte geopolitische Gruppierungen des 20. Jahrhunderts ab und validieren die Pipeline gegen historisches Wissen.

Ergebnis 3 — Bereinigung schlägt Modellwahl.

Das Entfernen von Wikipedia-Navigation vor NER brachte größere Genauigkeitsgewinne als der Wechsel des NLP-Modells — Datenqualität führt, nicht Modellwahl.

Ergebnis 4 — Alias-Normalisierung ist essenziell für Entitätsnetzwerke.

Ohne kanonische Alias-Auflösung erscheint dasselbe Land als mehrere Knoten und die echte Struktur des Netzwerks zerfällt. Aliasing ist ein nicht optionaler Preprocessing-Schritt.

MATERIALIEN

`</>` [GitHub-Repository](#)