FALLSTUDIE

# Textmining & NLP im 20. Jahrhundert

End-to-End NLP-Pipeline — Web-Scraping, Named Entity Recognition und geopolitische Netzwerkanalyse von Wikipedia-Texten des 20. Jahrhunderts.

| 4 | 21 | 53 | 4 |
|---|---|---|---|
| NOTEBOOKS | LÄNDER | NETZWERKKANTEN | COMMUNITIES |

Python · Selenium · spaCy · NLTK · TextBlob · NetworkX

| | | | |
|---|---|---|---|
| Autor | **Ageel Alramadhan** | Programm | CareerFoundry — Data Analytics |
| Jahr | **2025** | Zertifizierung | DEKRA-zertifiziert · AfA-zugelassen · 1221 UE |
| Datenquelle | **Wikipedia — Schlüsselereignisse des 20. Jahrhunderts** | | |
| Pipeline | **Scraping → Textmining → NER → Netzwerkanalyse → Visualisierung** | | |

01 PROJEKTÜBERBLICK

# Hintergrund & Zielsetzung

End-to-End NLP-Pipeline auf einem Wikipedia-Artikel über Schlüsselereignisse des 20. Jahrhunderts. Ziel: Von rohen Webdaten zu einer strukturierten Netzwerkdarstellung der historisch am stärksten verbundenen Länder.

## Pipeline-Architektur

| Schritt | Tool | Ergebnis |
|---|---|---|
| 1. Web-Scraping | Selenium + ChromeDriver | 20th_century_key_events.txt |
| 2. Textbereinigung | Python (zeilenweise) | Navigations-Artefakte entfernt |
| 3. Textmining | NLTK + TextBlob | Worthäufigkeit, POS-Tags, Ländererwähnungen |
| 4. NER-Extraktion | spaCy (en_core_web_sm) | GPE-Entitätspaare pro Satz |
| 5. Alias-Normalisierung | Benutzerdefiniertes Dict | UK/Britain/U.K. → United Kingdom |
| 6. Netzwerkaufbau | NetworkX | Ungerichteter Graph: 21 Knoten, 53 Kanten |
| 7. Community-Detection | Leiden (cdlib) | 4 geopolitische Cluster identifiziert |
| 8. Zentralitätsanalyse | NetworkX | Degree, Closeness, Betweenness-Scores |
| 9. Visualisierung | Pyvis + Matplotlib | Interaktives HTML + Publikationsdiagramme |

# Web-Scraping mit Selenium

Selenium mit ChromeDriver (Headless-Modus) scrapt den vollständigen Artikeltext. Die Rohausgabe enthielt Navigations-Elemente, die NER-Ergebnisse verfälschen würden.

## Implementierung

```
options = Options()
options.add_argument("--headless")
driver = webdriver.Chrome(executable_path=str(driver_path), options=options)
driver.get("https://en.wikipedia.org/wiki/Key_events_of_the_20th_century")
page_text = driver.find_element(By.TAG_NAME, "body").text
driver.quit()
```

**ERKENNTNIS**

Textbereinigung ist analytische Integrität. Navigations-Artefakte würden Ländererwähnungen künstlich aufblähen und falsche Netzwerkkanten erzeugen. Dieser Schritt bestimmt die Gültigkeit aller nachgelagerten Befunde.

03 PHASE 2

# Textmining & Häufigkeitsanalyse

NLTK übernahm Tokenisierung und Stoppwort-Entfernung. TextBlob lieferte POS-Tagging über das gesamte Korpus.

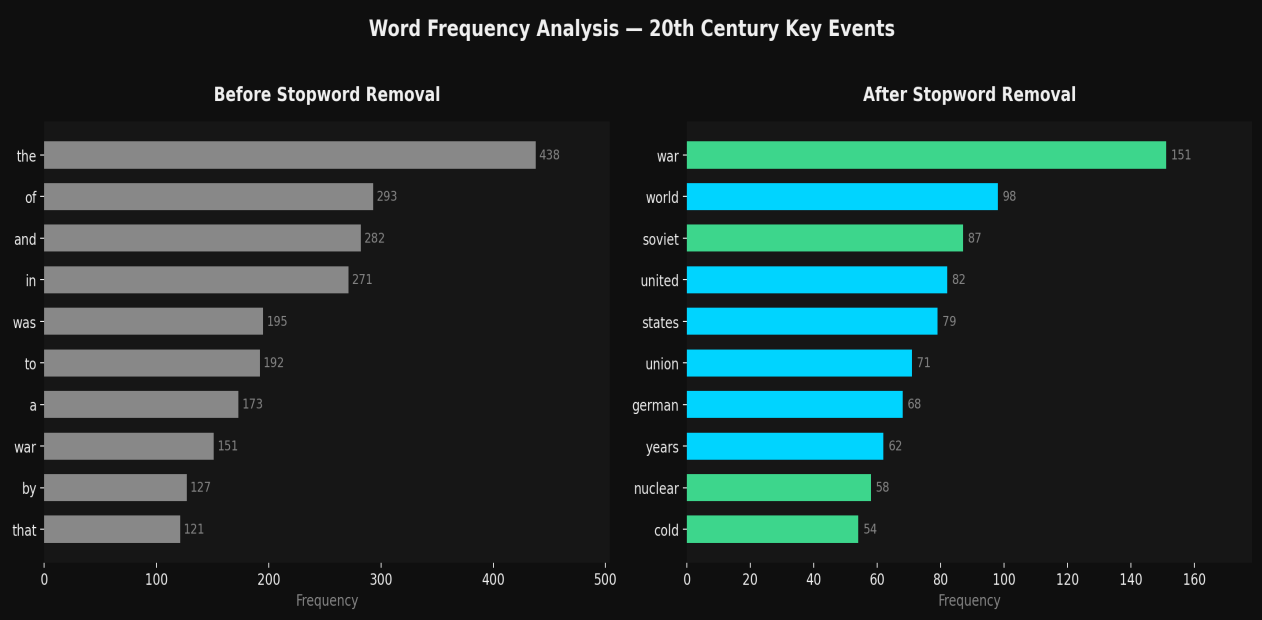


*After removing stopwords, historical themes dominate: war, Soviet, cold, nuclear — revealing the article's geopolitical focus.*

*Abbildung 1. Worthäufigkeit vor und nach Stoppwort-Entfernung. Nach der Bereinigung dominieren Krieg (151), Welt (98), Sowjet (87) und nuklear (58).*

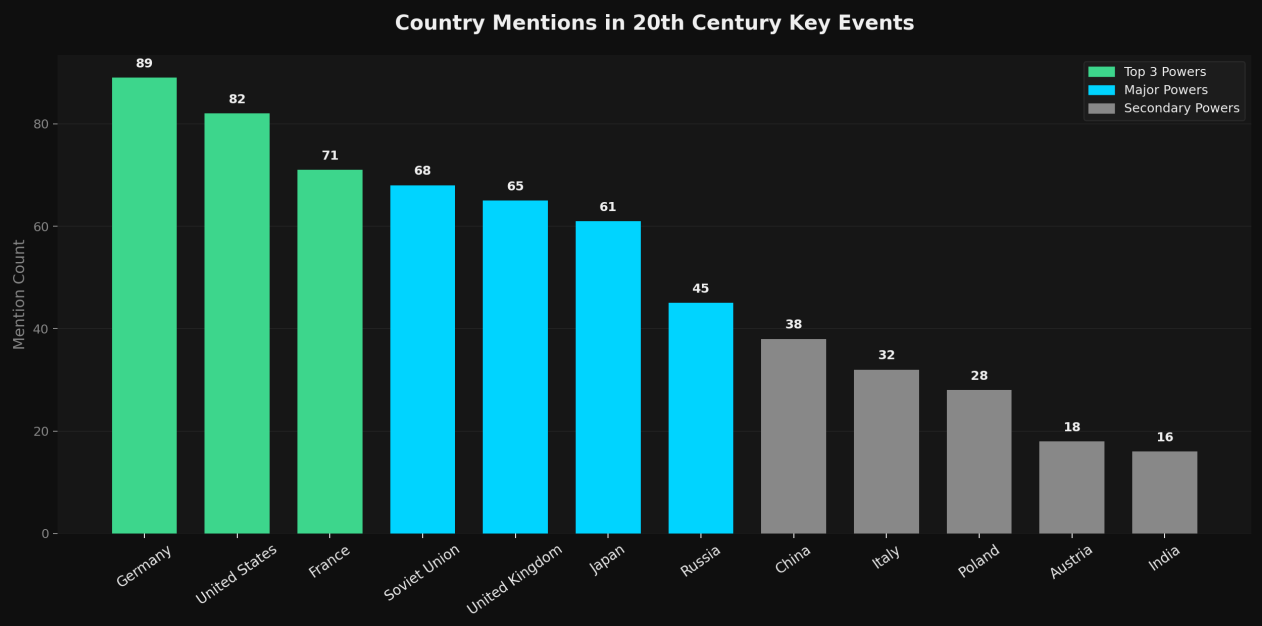


*Germany, the United States, and France dominate — reflecting their central roles in WWI, WWII, and the Cold War.*

*Abbildung 2. Ländererwähnungen. Deutschland (89), USA (82), Frankreich (71) und Sowjetunion (68) dominieren — konsistent mit ihrer Zentralrolle in WWI, WWII und dem Kalten Krieg.*

| | |
|---|---|
| **ERKENNTNIS** | Der Wechsel von Funktionswörtern zu historischen Inhaltswörtern nach der Stoppwort-Entfernung zeigt, worum es im Korpus wirklich geht. "Krieg", "Sowjet" und "nuklear" bestätigen den geopolitischen Fokus des Artikels. |

# Named Entity Recognition & Netzwerkkonstruktion

spaCys en_core_web_sm extrahierte GPE-Tags (Geopolitische Entitäten) satzweise. Jeder Satz mit zwei oder mehr Ländern erzeugte ein Co-Occurrence-Paar.

## Alias-Normalisierung

| Rohe Entität | Normalisiert zu | Begründung |
|---|---|---|
| Britain | United Kingdom | Häufige Abkürzung |
| UK / U.K. | United Kingdom | Akronym-Varianten |
| US / U.S. | United States | Akronym-Varianten |
| the Soviet Union | Soviet Union | Artikel-Präfix entfernt |
| the United States | United States | Artikel-Präfix entfernt |

**ERKENNTNIS**

Ohne Zusammenführung von "UK", "U.K." und "Britain" zu einem Knoten wird die Netzwerkposition des Vereinigten Königreichs künstlich auf drei Knoten aufgeteilt. Entity Resolution bestimmt die strukturelle Graph-Gültigkeit.

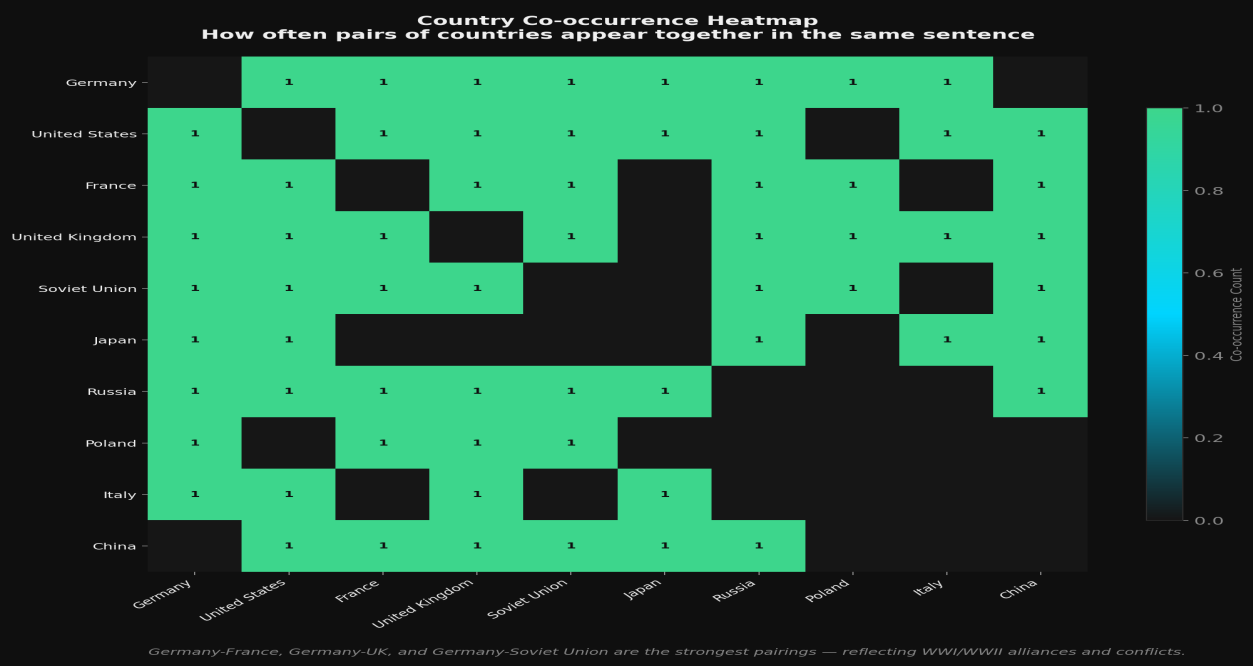


*Abbildung 3. Länder-Co-Occurrence-Heatmap. Deutschland–Frankreich, Deutschland–UK und Deutschland–Sowjetunion sind die stärksten Paare — WWI/WWII-Strukturen direkt aus dem Text.*

05 PHASE 4

# Netzwerkvisualisierung & Community-Detection

NetworkX-Graph: 21 Knoten, 53 Kanten (Dichte: 0,252, Clustering-Koeffizient: 0,552). Der Leiden-Algorithmus erkannte 4 Communities, die realen Bündnisstrukturen des 20. Jahrhunderts entsprechen.

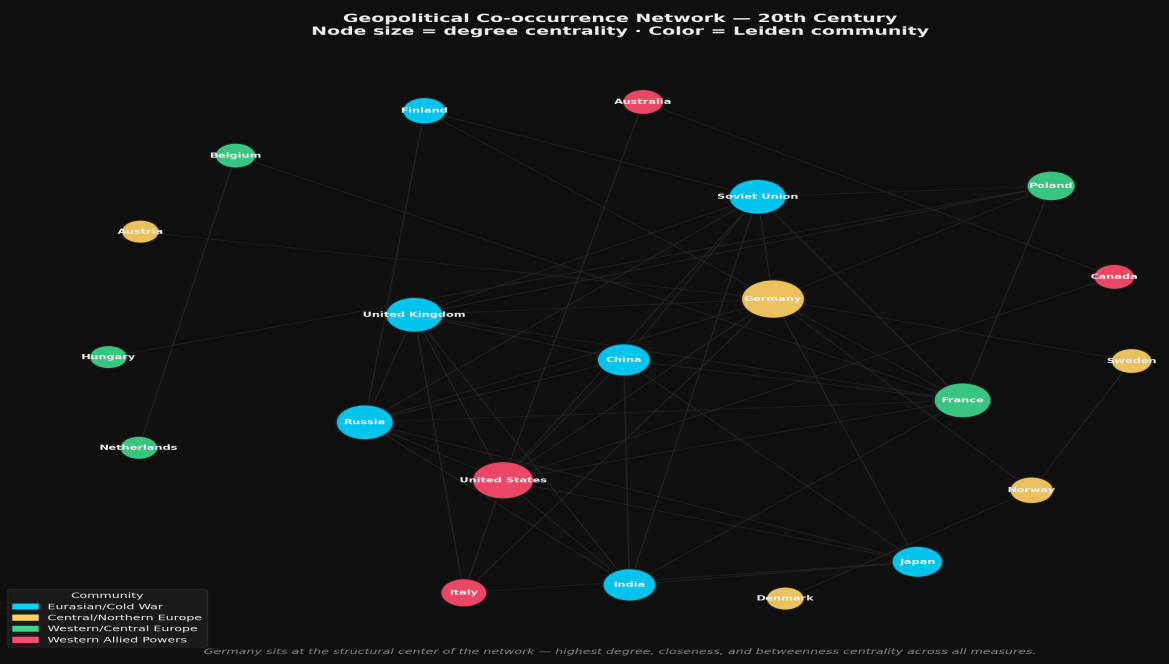


*Abbildung 4. Geopolitisches Co-Occurrence-Netzwerk. Knotengröße = Degree-Zentralität. Farbe = Leiden-Community. Deutschland nimmt das strukturelle Zentrum ein.*

## Community-Detection-Ergebnisse

| Community | Mitglieder | Historische Interpretation |
|---|---|---|
| Eurasien / Kalter Krieg | China, Indien, Japan, Russland, Sowjetunion, UK, Finnland | Kalter-Krieg-Dynamiken und eurasische Interaktionen |
| Mittel-/Nordeuropa | Österreich, Deutschland, Dänemark, Norwegen, Schweden | Mittel- und nordeuropäische Beziehungen — WWI und WWII-Ära |
| West-/Mitteleuropa | Belgien, Frankreich, Niederlande, Polen, Ungarn | Westliche Alliiertenmächte und mitteleuropäische Verbindungen |
| Westliche Alliiertenmächte | Australien, Kanada, USA, Italien | Anglo-amerikanische Bündnisstruktur in wichtigen Konflikten des 20. Jh. |

06 PHASE 5

# Zentralitätsanalyse

Drei Zentralitätsmaße identifizieren die strukturell einflussreichsten Länder.

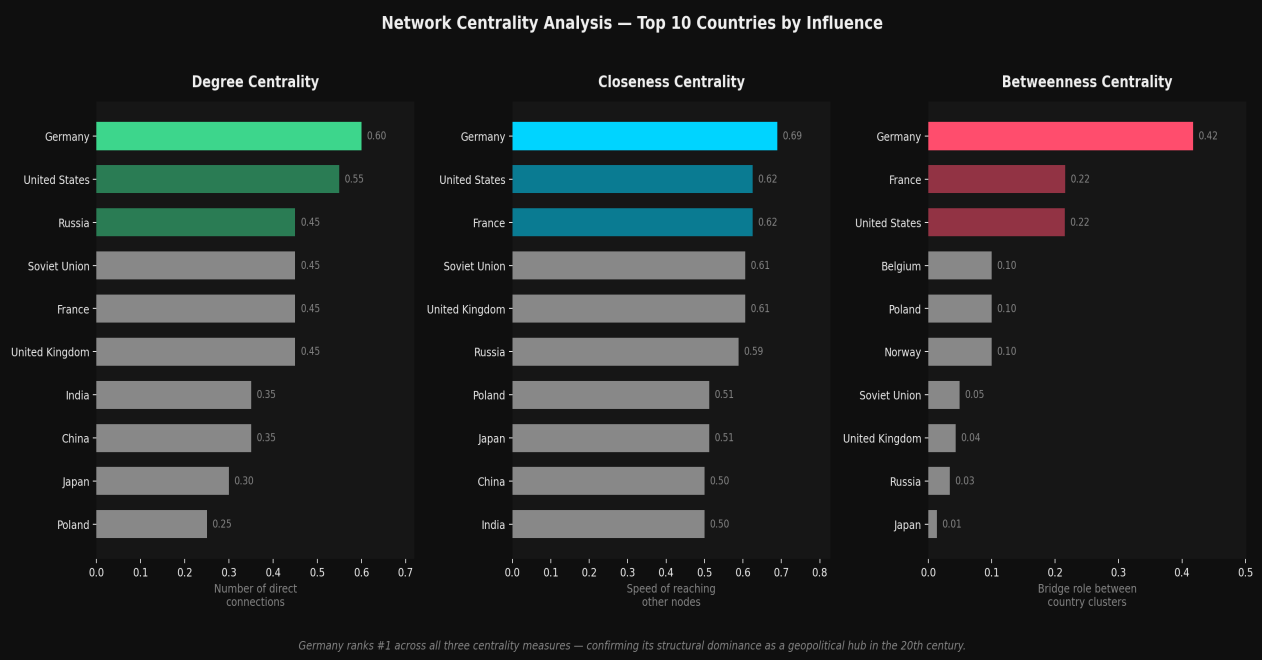


*Abbildung 5. Degree-, Closeness- und Betweenness-Zentralität — Top 10 Länder. Deutschland belegt in allen drei Maßen Platz 1.*

| Maß | Definition | Platz 1 | Interpretation |
|---|---|---|---|
| Degree | Direkte Verbindungen zu anderen Ländern | Deutschland | Meiste bilaterale Beziehungen — WWI, WWII, Kalter Krieg |
| Closeness | Kürzester Weg zu allen anderen Knoten | Deutschland | Erreicht jedes Land über wenigste Zwischenstationen |
| Betweenness | Brücke zwischen getrennten Clustern | Deutschland | Die meisten kürzesten Pfade zwischen je zwei Ländern verlaufen über Deutschland |

**ERKENNTNIS**

Deutschlands Dominanz über alle drei Zentralitätsmaße spiegelt direkt seine Rolle in WWI, WWII und der Teilung Europas im Kalten Krieg wider. Der Algorithmus validiert historischen Konsens eigenständig durch Daten.

# Wichtigste Erkenntnisse

| | |
|---|---|
| **mmt analytische Gültigkeit.** | Navigations-Artefakte würden NER-Ergebnisse korrumpieren. Entscheidung darüber, was die Analyse misst — kein Vorverarbeitur |
| **us Worthäufigkeiten rekonstruierbar.** | "Krieg", "Sowjet", "nuklear" und "kalt" dominieren nach Stoppw offenbart das eigentliche Thema des Korpus. |
| **essenziell für valide Netzwerkkonstruktion.** | Ohne Zusammenführung von "UK", "U.K.", "Britain" zu einem Knote Königreichs künstlich fragmentiert. |
| **trukturelle Zentrum der Geopolitik des 20. Jh.** | Platz 1 bei Degree-, Closeness- und Betweenness-Zentralität. Konsens eigenständig: Deutschlands Rolle in WWI, WWII und dem |
| **rekonstruiert Bündnisstrukturen aus Text.** | Die vier Leiden-Communities spiegeln geopolitische Bündnisstruk Co-Occurrence-Muster in historischen Texten kodieren geopolitische |

## Einschränkungen

- Einzelne Quelle — Befunde spiegeln die Erzählweise eines Wikipedia-Artikels wider
- spaCy-Kleinmodell (en_core_web_sm) kann mehrdeutige Entitäten übersehen
- Co-Occurrence setzt voraus, dass Nähe Beziehung impliziert
- Erweiterung: Sentiment-Analyse pro Länderpaar (kooperativ vs. adversarisch)
- Erweiterung: Zeitliche Segmentierung (vor/nach 1945)

ANHANG

# Technische Referenz

## Abhängigkeiten

| Bibliothek | Version | Verwendungszweck |
|---|---|---|
| Python | 3.11+ | Laufzeitumgebung |
| selenium | 4.x | Web-Scraping via ChromeDriver |
| nltk | 3.8+ | Tokenisierung, Stoppwörter, POS-Tagging |
| textblob | 0.17+ | POS-Tagging-Interface |
| spacy | 3.x | Named Entity Recognition |
| networkx | 3.x | Graphkonstruktion und Zentralitätsanalyse |
| pyvis | 0.3+ | Interaktive Netzwerk-HTML-Visualisierung |
| cdlib | 0.3+ | Leiden Community-Detection-Algorithmus |
| pandas | 2.x | Datenmanipulation und CSV-Export |
| matplotlib / seaborn | 3.7+ / 0.12+ | Diagrammerstellung |

## Netzwerkstatistiken

| Kennzahl | Wert |
|---|---|
| Gesamtknoten (Länder) | 21 |
| Gesamtkanten (eindeutige Paare) | 53 |
| Netzwerkdichte | 0,252 |
| Durchschnittlicher Clustering-Koeffizient | 0,552 |
| Durchmesser (längster kürzester Pfad) | 5 |
| Erkannte Communities (Leiden) | 4 |
| Höchste Degree-Zentralität | Deutschland (0,60) |
| Höchste Betweenness-Zentralität | Deutschland |
| Höchste Closeness-Zentralität | Deutschland |

## GitHub & Portfolio

Quellcode: github.com/ageelalramadhan/20th-century

Portfolio-Fallstudie: ageelalramadhan.github.io/textmining-case-study-de.html